

UNIVERSIDADE FEDERAL DE PERNAMBUCO

Centro de Informática

Bacharelado em Ciência da Computação

**Benchmark de Modelos Preditivos para Séries
Temporais Curtas: um estudo aplicado a programas
rurais em Pernambuco**

Kailane Eduarda Felix da Silva

Recife, 2026

Resumo

Palavras-chave: séries temporais, previsão de demanda, ARIMA, Random Forest, LightGBM, walk-forward cross-validation, políticas públicas.

Sumário

1	Introdução	4
1.1	Motivação	4
1.2	Objetivos	4
1.3	Organização do Texto	4
2	Referencial Teórico	6
2.1	Previsão de Séries Temporais Curtas	6
2.2	Modelos Estatísticos Clássicos	6
2.2.1	ARIMA	6
2.2.2	Suavização Exponencial (ETS)	6
2.3	Aprendizado de Máquina para Séries Temporais	6
2.3.1	Engenharia de Features com Lags	6
2.3.2	Random Forest	6
2.3.3	LightGBM	6
2.4	Validação de Modelos Temporais	6
2.5	Data Leakage em Séries Temporais	6
3	Dados e Pré-processamento	7
3.1	Descrição do Conjunto de Dados	7
3.2	Pré-processamento	7
3.2.1	Limpeza e Padronização	7
3.2.2	Expansão do Grid Completo	7
3.2.3	Codificação de Variáveis Categóricas	8
3.3	Engenharia de Features	8
4	Metodologia	9
4.1	Modelos Avaliados	9
4.1.1	Modelos Estatísticos	9
4.1.2	Modelos de ML	9
4.2	Modos de Treinamento	9
4.3	Métrica de Avaliação	9
4.4	Protocolo de Validação	10

4.4.1	Benchmark de Fold Único	10
4.4.2	Walk-forward Cross-validation	10
4.5	Problemas Identificados e Soluções	11
4.5.1	Problema 1 — Comparação em Granularidades Distintas	11
4.5.2	Problema 2 — Data Leakage via <code>lag_1</code>	11
4.5.3	Problema 3 — Leakage Residual em Features Derivadas	11
5	Resultados e Discussão	12
5.1	Benchmark de Fold Único (2025)	12
5.2	Walk-forward Cross-validation	12
5.3	Discussão	13
5.3.1	POR_SETOR versus GLOBAL	13
5.3.2	ARIMA como Modelo Mais Robusto	13
5.3.3	Alta Variância dos Modelos de ML no CV	13
5.3.4	Limitações	13
6	Conclusão	14

1 Introdução

A capacidade de prever com antecedência o número de beneficiários de programas de apoio rural é fundamental para o planejamento e alocação eficiente de recursos públicos. No entanto, dados históricos em granularidade municipal costumam abranger poucos anos, impondo restrições severas ao treinamento de modelos de aprendizado de máquina.

Este trabalho propõe um benchmark sistemático de modelos preditivos aplicados a séries temporais anuais de beneficiários de três programas rurais em Pernambuco — Fruticultura Irrigada, Zona Canavieira e Pesca Artesanal —, cobrindo o período de 2021 a 2025 e 101 municípios. O objetivo central é identificar qual família de modelos oferece a melhor relação entre acurácia e robustez quando o histórico disponível é limitado a cinco pontos por série.

1.1 Motivação

1.2 Objetivos

Os objetivos específicos deste trabalho são:

- Comparar modelos estatísticos (ARIMA, ETS), de aprendizado de máquina clássico (Regressão Linear, Árvore de Decisão) e moderno (Random Forest, LightGBM) numa tarefa de previsão com séries curtas;
- Avaliar o impacto de diferentes estratégias de treinamento — modelo global versus modelo por setor (*POR_SETOR*);
- Implementar validação *walk-forward* com múltiplos folds para medir a estabilidade dos modelos, evitando conclusões baseadas em um único ano de teste;
- Identificar e documentar fontes de *data leakage* comuns em séries temporais curtas e suas consequências nos resultados reportados.

1.3 Organização do Texto

O restante do trabalho está organizado da seguinte forma: a Seção 2 apresenta o referencial teórico; a Seção 3 descreve os dados e o pré-processamento; a Seção 4 detalha

os modelos e o protocolo de validação; a Seção 5 apresenta e discute os resultados; a Seção 6 conclui o trabalho e aponta direções futuras.

2 Referencial Teórico

2.1 Previsão de Séries Temporais Curtas

2.2 Modelos Estatísticos Clássicos

2.2.1 ARIMA

2.2.2 Suavização Exponencial (ETS)

2.3 Aprendizado de Máquina para Séries Temporais

2.3.1 Engenharia de Features com Lags

2.3.2 Random Forest

2.3.3 LightGBM

2.4 Validação de Modelos Temporais

2.5 Data Leakage em Séries Temporais

3 Dados e Pré-processamento

3.1 Descrição do Conjunto de Dados

Os dados utilizados neste trabalho são registros anuais de beneficiários de três programas rurais administrados pelo X, cobrindo 101 municípios de Pernambuco entre 2021 e 2025. O conjunto original contém 517 observações distribuídas entre três programas: Fruticultura Irrigada, Zona Canavieira e Pesca Artesanal.

Tabela 1: Resumo do conjunto de dados

Atributo	Valor
Período	2021–2025 (5 anos)
Municípios	101
Programas	3
Observações originais	517
Granularidade	Município $\times$ Programa $\times$ Ano

Uma característica relevante do conjunto é que nem todo município possui registros para todos os programas em todos os anos, gerando lacunas na série. Essas lacunas são tratadas conforme descrito na Seção 3.2.2.

3.2 Pré-processamento

3.2.1 Limpeza e Padronização

3.2.2 Expansão do Grid Completo

Para garantir que todos os modelos operem sobre séries sem lacunas temporais, foi criado o produto cartesiano completo de municípios, programas e anos já presentes no conjunto original. Combinações sem registro real receberam o valor zero de beneficiários, estratégia conservadora que assume ausência de atividade em vez de dado faltante.

Após a expansão, o conjunto passou de 517 para observações.

3.2.3 Codificação de Variáveis Categóricas

3.3 Engenharia de Features

Todas as features foram construídas de forma a não introduzir *data leakage* — ou seja, nenhuma delas utiliza informações do período de teste nem do ano imediatamente anterior ($t - 1$) ao alvo, conforme discutido na Seção 4.5.

Tabela 2: Features utilizadas nos modelos de ML (versão final, v5)

Feature	Descrição
lag_2	Beneficiários em $t - 2$
lag_3	Beneficiários em $t - 3$
rolling_mean_2	Média de lag_2 e lag_3: $(lag_2 + lag_3)/2$
trend	Variação absoluta: $lag_2 - lag_3$
growth_rate	Variação proporcional: $(lag_2 - lag_3)/lag_3$; zero quando $lag_3 = 0$
zero_historico	Indicador binário: 1 se $lag_2 = lag_3 = 0$
ano_rel	Anos desde o início da série (tendência linear)
programa_total_lag2	Soma de lag_2 de todos os municípios do programa no mesmo ano
share_municipio	Peso relativo do município no programa: $lag_2/(programa_total_lag_2 + 1)$

4 Metodologia

4.1 Modelos Avaliados

Seis modelos foram selecionados, representando três famílias distintas, com o objetivo de cobrir um espectro amplo de complexidade e suposições sobre os dados.

Tabela 3: Modelos avaliados por família

Família	Modelo	Configuração
Estatístico	ARIMA	Ordem (1, 1, 0)
Estatístico	ETS (Holt Linear)	Tendência aditiva, sem sazonalidade
ML Clássico	Regressão Linear	Sem regularização
ML Clássico	Árvore de Decisão	<code>max_depth=4</code>
ML baseado em Ensemble	Random Forest	200 estimadores, <code>max_depth=6</code> , <code>min_samples_leaf=10</code>
ML baseado em Ensemble	LightGBM	200 estimadores, <code>lr=0.05</code> , <code>max_depth=4</code>

4.1.1 Modelos Estatísticos

4.1.2 Modelos de ML

4.2 Modos de Treinamento

Cada modelo foi avaliado em dois modos:

- **GLOBAL:** um único modelo treinado com dados de todos os municípios e programas simultaneamente.
- **POR_SETOR:** um modelo treinado separadamente para cada programa, permitindo que o modelo capture dinâmicas específicas de cada setor.

4.3 Métrica de Avaliação

A métrica principal adotada é o Erro Percentual Absoluto Médio (*Mean Absolute Percentage Error*, MAPE), definido como:

$$\text{MAPE} = \frac{1}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right| \times 100\% \quad (1)$$

onde y_t é o valor real e $\hat{y}_t$ é o valor previsto no período t . Observações com $y_t \approx 0$ são excluídas do cálculo para evitar distorções numéricas.

Para garantir comparabilidade entre modelos estatísticos (que operam em séries agregadas por programa) e modelos de ML (que operam no nível município), as previsões de ML são somadas por programa antes do cálculo do MAPE. Essa função é denominada `evaluate_aggregated()` na implementação.

São reportados também MAE e RMSE como métricas complementares.

4.4 Protocolo de Validação

4.4.1 Benchmark de Fold Único

4.4.2 Walk-forward Cross-validation

A validação principal utiliza a estratégia *expanding window* (janela expansível), em que o conjunto de treino cresce a cada fold enquanto o conjunto de teste avança um ano por vez. Com dados de 2021 a 2025 e mínimo de dois anos de treino, foram gerados três folds:

Tabela 4: Folds do walk-forward cross-validation

Fold	Treino	Teste
1	2021–2022	2023
2	2021–2023	2024
3	2021–2024	2025

O desempenho final de cada modelo no CV é reportado como média e desvio padrão do MAPE entre os folds válidos (modelos estatísticos requerem no mínimo 3 pontos de treino; folds com série insuficiente são excluídos automaticamente).

4.5 Problemas Identificados e Soluções

4.5.1 Problema 1 — Comparação em Granularidades Distintas

4.5.2 Problema 2 — Data Leakage via `lag_1`

A inclusão de `lag_1` (valor de $t - 1$) como feature de ML equivale, em séries estáveis de curto horizonte, a fornecer ao modelo a resposta que ele deveria prever. Isso ficou evidenciado pelo desempenho da Árvore de Decisão na Pesca Artesanal: MAPE de 0,03% com `lag_1` respondendo por 98,4% da importância de features — o modelo simplesmente repetia o ano anterior.

Tabela 5: Evidência do leakage via `lag_1` — Árvore de Decisão, Pesca Artesanal

Município	Real 2025	Previsto	Erro abs.	<code>lag_1</code>
Goiana	1817	1810,00	7,00	1810
Recife	600	596,00	4,00	592
Ipojuca	186	89,31	96,69	98
Igarassu	511	443,25	67,75	477

Solução: `lag_1` foi removido inteiramente do pré-processamento. As features `rolling_mean_2` e `trend`, que dependiam internamente de `lag_1`, foram recalculadas usando `lag_2` e `lag_3`.

4.5.3 Problema 3 — Leakage Residual em Features Derivadas

5 Resultados e Discussão

5.1 Benchmark de Fold Único (2025)

Tabela 6: Resultados do benchmark — fold único (ano de teste: 2025)

Modelo	Modo	Programa	MAPE%
RandomForest	POR_SETOR	Fruticultura Irrigada	2,30
RandomForest	POR_SETOR	Zona Canavieira	3,00
LightGBM	POR_SETOR	Fruticultura Irrigada	3,30
RandomForest	GLOBAL	Todos	3,76
ETS (Holt Linear)	POR_SETOR	Zona Canavieira	3,78
ARIMA	GLOBAL	Todos	4,06
ARIMA	POR_SETOR	Fruticultura Irrigada	4,31
DecisionTree	POR_SETOR	Pesca Artesanal	7,48
RandomForest	POR_SETOR	Pesca Artesanal	7,74
ARIMA	POR_SETOR	Pesca Artesanal	9,32

5.2 Walk-forward Cross-validation

Tabela 7: Walk-forward CV — média de 3 folds (2023, 2024, 2025)

Modelo	Modo	Programa	MAPE médio	Desvio	Folds
ARIMA	POR_SETOR	Fruticultura Irrigada	5,84%	$\pm 2,16$	2
ARIMA	POR_SETOR	Pesca Artesanal	6,75%	$\pm 3,64$	2
ARIMA	GLOBAL	Todos	7,46%	$\pm 4,81$	2
RandomForest	POR_SETOR	Fruticultura Irrigada	7,83%	$\pm 9,78$	3
DecisionTree	POR_SETOR	Pesca Artesanal	9,55%	$\pm 7,68$	3
RandomForest	POR_SETOR	Pesca Artesanal	9,91%	$\pm 5,70$	3
DecisionTree	POR_SETOR	Fruticultura Irrigada	10,51%	$\pm 2,80$	3

5.3 Discussão

5.3.1 POR_SETOR versus GLOBAL

5.3.2 ARIMA como Modelo Mais Robusto

5.3.3 Alta Variância dos Modelos de ML no CV

5.3.4 Limitações

- **Tamanho da série:** cinco pontos anuais por série limitam a generalização de qualquer modelo e impõem incerteza elevada nas estimativas de CV.
- **Zeros estruturais:** municípios sem histórico em um dado programa recebem valor zero, o que pode distorcer features baseadas em lags e inflacionar o MAPE quando o valor real também é zero.
- **Ausência de sazonalidade:** com dados anuais, não é possível modelar padrões intra-anuais que possam existir nos programas.

6 Conclusão

Referências

- [1] R. J. Hyndman e G. Athanasopoulos, *Forecasting: Principles and Practice*, 3^a ed. OTexts, 2021. Disponível em: <https://otexts.com/fpp3/>
- [2] S. Makridakis, E. Spiliotis e V. Assimakopoulos, “M5 accuracy competition: Results, findings, and conclusions,” *International Journal of Forecasting*, vol. 38, n. 4, pp. 1346–1364, 2022.
- [3] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, n. 1, pp. 5–32, 2001.
- [4] G. Ke et al., “LightGBM: A highly efficient gradient boosting decision tree,” *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.
- [5] G. E. P. Box, G. M. Jenkins, G. C. Reinsel e G. M. Ljung, *Time Series Analysis: Forecasting and Control*, 5^a ed. Wiley, 2015.
- [6] C. Bergmeir e J. M. Benítez, “On the use of cross-validation for time series predictor evaluation,” *Information Sciences*, vol. 191, pp. 192–213, 2012.
- [7] F. Pedregosa et al., “Scikit-learn: Machine learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.